

# Detecção Automatizada de Estratégias *Call2Go*: Pipeline *Cross-Platform* para a Indústria Musical Brasileira

Lucas Fiori Magalhães Machado<sup>1</sup>

<sup>1</sup>Bacharelado em Ciência da Computação  
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)  
Belo Horizonte – MG, Brasil

lucasfmm54@gmail.com

**Abstract.** *This paper investigates the effectiveness of Call2Go—action calls in YouTube video descriptions that redirect audiences to Spotify—as a cross-platform strategy in the Brazilian music industry. The analytical universe is built via Reciprocal Rank Fusion over artists in the Brazilian Spotify and YouTube charts, and an automated multilayer regex detector is validated against blind human annotation using Cohen’s  $\kappa$ . With non-parametric tests, a logistic-regression confounder check, and machine-learning techniques, we find that videos using Call2Go tend to have significantly higher view counts on YouTube, show no measurable effect on Spotify popularity, and that YouTube activity precedes chart entry. The data pipeline is reproducible and deterministic.*

**Resumo.** *Este trabalho investiga a efetividade da estratégia Call2Go—chamadas de ação em descrições de vídeos do YouTube que redirecionam a audiência ao Spotify—como mecanismo cross-platform no mercado musical brasileiro. O universo analítico é construído por Reciprocal Rank Fusion sobre os artistas dos charts brasileiros de Spotify e YouTube, e um detector automatizado baseado em regex multicamada é validado contra anotação humana às cegas pelo Kappa de Cohen. Com testes não paramétricos, verificação de confundidor por regressão logística e técnicas de aprendizado de máquina, observa-se que vídeos com Call2Go tendem a ter mais visualizações no YouTube, sem efeito mensurável na popularidade do Spotify, e que a atividade no YouTube antecede a entrada nos charts. O pipeline de dados é reprodutível e determinístico.*

## 1. Introdução

A transformação digital da indústria fonográfica nas últimas duas décadas mudou as relações entre produção, distribuição e consumo de música. O relatório anual da Federação Internacional da Indústria Fonográfica (IFPI) registrou, em 2023, que as receitas provenientes de serviços de *streaming* responderam por 67% do total global da música gravada—uma mudança expressiva no modelo de negócios do setor [IFPI 2023]. O Brasil ocupa posição de destaque nesse cenário: dados públicos da Pró-Música Brasil [Pró-Música Brasil 2026] situam o país entre os dez maiores mercados fonográficos do planeta, com taxas de crescimento em *streaming* consistentemente acima da média global. A penetração de internet de alta velocidade e o aumento expressivo no consumo de áudio *on demand* no país, acompanhados pela PNAD Contínua TIC do IBGE [IBGE 2026], ampliam a relevância empírica do fenômeno. Dentro desse ecossistema, duas plataformas

assumiram papel central: o YouTube, maior repositório de vídeos do mundo e principal canal de descoberta musical [Covington et al. 2016], e o Spotify, líder global em *streaming* de áudio com mais de 600 milhões de usuários ativos.

Nesse contexto, este trabalho estuda a estratégia denominada *Call2Go*. O termo é adotado a partir de um estudo recente sobre influenciadores infantis no Instagram e no YouTube [Bouchardet et al. 2025] e, aqui, é adaptado ao mercado musical para descrever chamadas inseridas na descrição de um vídeo do YouTube—seja um *link* direto ao Spotify, seja uma chamada textual de ação—com o propósito de redirecionar o espectador para a plataforma de *streaming* de áudio. A lógica subjacente é que a audiência conquistada no YouTube, de acesso gratuito e amplo alcance, pode ser convertida em ouvintes recorrentes no Spotify, cuja monetização por *stream* é mais vantajosa para artistas e distribuidoras [Wlömert and Papies 2016, Aguiar and Waldfogel 2021].

A investigação científica sobre as dinâmicas *cross-platform* entre YouTube e Spotify na música digital ainda se encontra em estágio formativo [Aguiar and Waldfogel 2021]. Os estudos existentes concentram-se predominantemente em análises agregadas de mercado ou em fenômenos observados em plataformas isoladas, sem abordar sistematicamente os mecanismos de transferência de audiência entre YouTube e Spotify [Napoli 2010]. Ademais, a ausência de ferramentas automatizadas validadas para a detecção de *Call2Go* em larga escala representa um obstáculo metodológico significativo: a anotação manual de grandes *corpora* é ao mesmo tempo impraticável operacionalmente e sujeita a vieses de subjetividade entre anotadores [Krippendorff 2004]. A lacuna identificada é, portanto, dupla: **empírica**, pela ausência de evidências sobre a eficácia da estratégia no mercado brasileiro, e **metodológico**, pela inexistência de instrumentos confiáveis para sua detecção automatizada em escala.

Este trabalho endereça diretamente essa lacuna ao investigar empiricamente a **efetividade da estratégia *Call2Go*** como mecanismo de *cross-platform* entre YouTube e Spotify no mercado musical brasileiro. Para viabilizar a análise em escala, propõe-se, implementa-se e valida-se um sistema automatizado de detecção baseado em expressões regulares [Friedl 2006] multicamada, cujo protocolo de validação adversarial às cegas, ancorado no coeficiente Kappa de Cohen [Cohen 1960, Landis and Koch 1977] com intervalos de confiança via *bootstrap* [Efron 1979], assegura a confiabilidade do instrumento de mensuração. Os dados coletados são empregados para testar hipóteses sobre o impacto estatístico do *Call2Go* no engajamento em ambas as plataformas via testes não paramétricos [Mann and Whitney 1947, Spearman 1904], investigar a direcionalidade da relação *cross-platform*, analisar a defasagem temporal entre publicação no YouTube e entrada dos artistas nos *charts*, e aplicar técnicas de aprendizado de máquina supervisionado e não supervisionado [Pedregosa et al. 2011, Breiman 2001] para identificar preditores e perfis comportamentais.

As principais contribuições são: (i) um sistema determinístico e auditável de detecção em dois níveis com operadores OR e AND; (ii) um protocolo de validação adversarial às cegas com Kappa de Cohen e IC 95% *bootstrap*; (iii) um pipeline ETL reproduzível de 20 etapas integrando YouTube, Spotify e Last.fm; (iv) análise de defasagem temporal entre atividade no YouTube e *charts* Spotify para artistas brasileiros; e (v) adoção de *Reciprocal Rank Fusion* [Cormack et al. 2009] como critério de amostragem livre

de viés de seleção, complementada por análises de *Random Forest*, *K-means* e *PCA* via `scikit-learn` [Pedregosa et al. 2011].

O artigo está organizado da seguinte forma: a Seção 2 revisa a literatura relevante; a Seção 3 apresenta objetivos e hipóteses; a Seção 4 detalha o pipeline; a Seção 5 expõe os resultados; e a Seção 6 apresenta as conclusões e trabalhos futuros.

## 2. Revisão da Literatura

Esta seção revisa a literatura em três frentes que sustentam o trabalho: (i) o marketing *cross-platform* na música digital; (ii) a análise automatizada de conteúdo em plataformas; e (iii) a avaliação de confiabilidade de sistemas de classificação automática.

### 2.1. Marketing Digital e *Cross-Platform* na Música

A digitalização da cadeia produtiva musical transformou não apenas os canais de distribuição, mas os modelos de relacionamento entre artistas, intermediários e audiências. As plataformas digitais alteraram as dinâmicas de promoção, deslocando poder das grandes gravadoras para distribuidoras independentes e artistas [Aguilar and Waldfogel 2021]. YouTube e Spotify exercem funções complementares: o primeiro como plataforma de descoberta e videoconsumo, o segundo consolidando consumo recorrente em *stream* contabilizável [Wlömert and Papies 2016].

Essas estratégias seguem uma lógica de funil de marketing: o YouTube funciona como porta de entrada (amplo alcance e acesso gratuito) e o Spotify como etapa de conversão, em que o consumo recorrente é monetizável. Estudos demonstram efeitos assimétricos do Spotify sobre as receitas da indústria, sem abordar os mecanismos de direcionamento interplataforma [Wlömert and Papies 2016]. A fragmentação de audiências digitais, por sua vez, impõe desafios de medição e de atribuição de causalidade entre plataformas [Napoli 2010]. O mercado brasileiro figura entre os maiores do YouTube por horas assistidas [IFPI 2023] e experimenta uma das transições mais rápidas de consumo gratuito para *streaming* pago.

### 2.2. Análise Automatizada de Conteúdo em Plataformas Digitais

A análise de conteúdo é uma técnica consolidada para inferências replicáveis e válidas a partir de textos [Krippendorff 2004]. No campo de *Music Information Retrieval*, há catálogos de abordagens de análise automatizada de metadados musicais [Schedl et al. 2014]. Sistemas baseados em regras, como o motor *regex* [Friedl 2006] proposto neste trabalho, caracterizam-se por alta interpretabilidade, custo computacional negligenciável e comportamento determinístico—propriedades essenciais em contexto acadêmico onde reprodutibilidade e auditabilidade são requisitos metodológicos [Salganik 2019]. A esparsidade e o ruído de metadados de vídeo dificultam a extração consistente [Celma 2010], fenômeno agudo em descrições do YouTube, onde URLs encurtadas e redirecionadores ocultam o destino final dos *links*. A distinção entre menções narrativas (“10 milhões de *plays* no Spotify”) e chamadas de ação (“ouça no Spotify”) constitui o desafio central na análise: sistemas de *keyword matching* simples tratam ambos casos de forma idêntica, produzindo falsos positivos.

### 2.3. Confiabilidade em Sistemas de Classificação Automatizada

A avaliação de confiabilidade de sistemas de classificação automatizada ancora-se no índice  $\kappa$  de Cohen [Cohen 1960], medida pioneira de concordância além do esperado pelo acaso. A escala interpretativa de Landis e Koch [Landis and Koch 1977] é amplamente adotada:  $\kappa < 0,20$  (fraca),  $0,21-0,40$  (razoável),  $0,41-0,60$  (moderada),  $0,61-0,80$  (substancial),  $0,81-1,00$  (quase perfeita). Pesquisas computacionais em ciências sociais enfrentam um dilema entre escala e validade, mitigado por verificação humana sobre amostras adversariais que forçam o sistema a demonstrar robustez nos casos mais difíceis [Salganik 2019].

As principais abordagens para análise automatizada de conteúdo em plataformas digitais variam em **escala** (anotação manual e *keyword match* têm escala grande mas validação baixa devido à alta taxa de falsos positivos), **validação** (*regex* multicamada e NLP profundo apresentam validação alta) e **custo** (NLP profundo via *transformers* é altamente custoso computacionalmente, enquanto *regex* multicamada equilibra escala e validação ao preço de ser domínio-específico). A escolha por *regex* multicamada neste trabalho deriva exatamente desse *trade-off*: domínio-específico é aceitável quando o objeto de estudo é um padrão linguisticamente bem definido (as chamadas *Call2Go*), e o ganho em escala (milhares de vídeos analisados em segundos) viabiliza o estudo empírico.

## 3. Objetivos da Pesquisa

Esta seção apresenta o objetivo geral, os objetivos específicos e as hipóteses de pesquisa ( $H_0$  a  $H_4$ ) que orientam o trabalho.

### 3.1. Objetivo Geral

Investigar empiricamente a efetividade da estratégia *Call2Go* como mecanismo *cross-platform* no mercado musical brasileiro, por meio do desenvolvimento e validação de um sistema automatizado de detecção aplicado a um corpus de 2.495 vídeos sobre o universo Top-K (56 artistas) do Reciprocal Rank Fusion mensal aplicado a 276 artistas primários nos *charts* brasileiros de Janeiro–Abril 2026, analisando o impacto da estratégia em métricas de engajamento, a direcionalidade da relação entre YouTube e Spotify, e a defasagem temporal entre a atividade de publicação no YouTube e a entrada dos artistas nos *charts* Spotify.

### 3.2. Objetivos Específicos

1. Construir o universo analítico via *Reciprocal Rank Fusion* [Cormack et al. 2009] sobre os *charts* semanais Spotify Top 100 BR e YouTube Top 100 BR de Janeiro a Abril de 2026, definindo um Top-K como subconjunto representativo.
2. Coletar e estruturar o corpus via APIs do YouTube [Google 2024], Spotify [Spotify 2024] e Last.fm [Audiocrobbler 2024], em pipeline ETL reprodutível em Python 3.12 [Python Software Foundation 2024] com *pandas* [McKinney 2010], *SciPy* [Virtanen et al. 2020] e *scikit-learn* [Pedregosa et al. 2011].
3. Desenvolver um detector de *Call2Go* bicamada (vídeo e canal) com operadores OR e AND, distinguindo *links* diretos, redirecionadores e menções textuais, com filtragem automática de menções narrativas.


4. Validar o detector em *ground truth* humano às cegas (91 vídeos adversariais), reportando Kappa de Cohen [Cohen 1960] com IC 95% *bootstrap* [Efron 1979].
5. Testar  $H_2$  e  $H_3$  via Mann-Whitney U [Mann and Whitney 1947] e bidirecional via Spearman [Spearman 1904], com análise temporal ( $H_4$ ) e regressão logística [Hastie et al. 2009] (reportando *odds ratios*) como verificação de confundidor.
6. Aplicar técnicas de aprendizado de máquina [Breiman 2001, MacQueen 1967, Pearson 1901] para predição, *clustering* e visualização do espaço de artistas Top-K.

### 3.3. Hipóteses de Pesquisa

- $H_0$  O detector automatizado não apresenta concordância estatisticamente significativa com a classificação humana (acurácia  $< 85\%$ ).
- $H_1$  O detector atinge acurácia  $\geq 85\%$  em relação ao *ground truth* humano, validando a abordagem como metodologicamente confiável.
- $H_2$  Vídeos com *Call2Go* OR apresentam volume de visualizações significativamente maior no YouTube do que vídeos sem a estratégia.
- $H_3$  A presença de *Call2Go* OR está positivamente associada a maior pontuação de popularidade no Spotify.
- $H_4$  A atividade de publicação no YouTube antecede temporalmente a entrada do artista nos *charts* Spotify, e a intensidade dessa atividade pré-entrada correlaciona-se com o desempenho nos *charts*.

## 4. Metodologia

A Figura 1 apresenta o pipeline ETL e de análise, composto por 20 etapas sequenciais organizadas em seis blocos funcionais.



**Figura 1. Pipeline ETL e de validação (20 etapas). Cinza: extração e carga; verde: análise estatística; laranja: aprendizado de máquina; azul: validação cruzada independente.**

O detalhamento de cada etapa encontra-se nas subseções a seguir (construção do universo e coleta de dados, *scraping* de canais, detecção, *data warehouse* e protocolo de validação) e os resultados correspondentes na Seção 5.

#### 4.1. Construção da Base de Artistas e Coleta de Dados

O universo analítico é construído via **Reciprocal Rank Fusion** (RRF) [Cormack et al. 2009] aplicado a todos os artistas *primários* (primeiro artista de cada faixa) que aparecem em pelo menos uma semana dos *charts* Spotify Top 100 BR ou YouTube Top 100 BR de Janeiro a Abril de 2026 (17 *snapshots* semanais por plataforma, quatro meses). Os *charts* são alinhados em dimensionalidade (Top 100 em ambas plataformas) para evitar peso assimétrico no *score*. Para cada artista  $i$  e plataforma  $j \in \{SP, YT\}$ :

$$\text{score}_{i,j} = \frac{1}{n_{\text{meses}_j}} \sum_{m \in \{Jan, Feb, Mar, Abr\}} \frac{1}{\text{best\_rank}_{i,j,m}}$$

onde  $\text{best\_rank}_{i,j,m}$  é a melhor (menor) posição ocupada pelo artista  $i$  na plataforma  $j$  ao longo do mês  $m$ , e  $n_{\text{meses}_j} = 4$  fixo. O *score* combinado  $\text{score}_i = \text{score}_{i,SP} + \text{score}_{i,YT}$  é usado para ordenação global. O universo compreende 276 artistas primários, dos quais  $K = \max(20, \lceil 0,20 \cdot N \rceil) = 56$  formam o **Top-K** (cobrindo 82,9% do *score* acumulado), conjunto adotado para análises estatísticas e visualizações.

Para o YouTube, a coleta de vídeos usa o *endpoint* `playlistItems.list` (custo: 1 unidade de cota por chamada), acessando a *uploads playlist* de cada canal ao substituir o prefixo UC por UU para recuperar até 200 vídeos, ordenando localmente por `viewCount` e selecionando os 30 mais visualizados [Google 2024]. A coleta cobre 100% dos artistas Top-K do RRF, totalizando **2.495 vídeos** analisáveis (todos os 56 artistas do Top-K possuem ao menos um vídeo coletado).

Canais do tipo OAC (*Official Artist Channel*) foram tratados com busca automática do canal oficial principal. As métricas do Spotify foram coletadas via Spotify Web API [Spotify 2024] (*snapshot* 22/abr/2026), e métricas do Last.fm via API [Audioscrobbler 2024] cobrindo *listeners*, *scrobbles*, *top tracks* e *charts* brasileiros Top 200.

#### 4.2. Scraping Estruturado de Links de Canal

A aba “Sobre” dos canais do YouTube expõe *links* externos estruturados **não acessíveis** pela YouTube Data API v3, o que torna o *scraping* [Mitchell 2018] metodologicamente crítico (esses *links* respondem por 25,0% das detecções no corpus). O módulo opera em duas fases (extração de `ytInitialData` e *fallback regex* em `/about`) com tratamento de escape Unicode `\u0026` e modo *cache-first* para reprodutibilidade entre execuções.

#### 4.3. Detector de Call2Go: Regex Multicamada

O detector opera em dois níveis analíticos independentes, implementando oito regras (R1–R8) baseadas em *regex* [Friedl 2006]: (R1) *links* diretos a domínios proprietários (`open.spotify.com`, `spoti.fi`, `sptfy.com`); (R2) *labeled redirects* (`lnk.to`, `bit.ly`, `smarturl.it`) com proximidade do rótulo “spotify”; (R3) *token spotify* no

*path* da URL; (R4) chamadas de ação verbais (*ouça*, *disponível*, *stream*); (R5) *deep links* *spotify*:: (R6) agregadores de redes sociais com *path* *spotify* (*linktr.ee*, *lnk.bio*, *beacons.ai*); (R7) chamadas de ação com emoji musical próximo a “spotify”; e (R8) heurística *strict* que rebaixa vídeos auto-gerados pelo YouTube. Um pré-filtro de menções narrativas invalida padrões contextuais sem intenção de CTA (rankings, estatísticas de *streams*). As duas camadas geram as métricas **OR** (vídeo *ou* canal — métrica primária) e **AND** (vídeo *e* canal — sub-análise).

#### 4.4. Data Warehouse e Análises Estatísticas

Os dados coletados são carregados em um *data warehouse* SQLite com *star schema* de 6 tabelas: *dim\_artist*, *fact\_yt\_videos* (com colunas *has\_call2go* e *has\_call2go\_or*), *fact\_spotify\_metrics*, *fact\_lastfm\_metrics*, *fact\_lastfm\_chart\_artists* e *fact\_lastfm\_chart\_tracks*. O banco é reconstruído integralmente a cada execução (*batch rebuild*), garantindo consistência entre dados brutos e o artefato analítico.

Para os testes  $H_2$  e  $H_3$ , o Mann-Whitney U foi selecionado por ser não paramétrico, adequado para amostras de tamanhos distintos e robusto a *outliers* [Mann and Whitney 1947]. Adotou-se a alternativa unilateral (*greater*), coerente com a direcionalidade explícita das hipóteses ( $H_2$  e  $H_3$  postulam que vídeos com *Call2Go* geram *mais* views ou *maior* popularidade, não a possibilidade de gerarem menos). Para as análises bidirecional e temporal, a correlação de Spearman [Spearman 1904] foi adotada pela capacidade de detectar relações monotônicas não lineares. O nível de significância é  $\alpha = 0,05$  em todos os testes inferenciais.

A análise temporal ( $H_4$ ) define três janelas de observação relativas à data de entrada de cada artista no *chart* Spotify:  $[-30; 0]$ ,  $[-90; 0]$  e o período total de publicação no YouTube. A defasagem (*lag*) é calculada como a diferença em dias entre o primeiro vídeo do artista no YouTube e sua primeira aparição no *chart* Spotify BR de Janeiro–Abril 2026.

**Análises de Aprendizado de Máquina.** Como complemento aos testes estatísticos clássicos, aplicam-se três técnicas via *scikit-learn* [Pedregosa et al. 2011]: (i) *Random Forest* [Breiman 2001] com  $n_{\text{trees}} = 200$  e validação cruzada estratificada de 5 folds para prever adoção de *Call2Go* a partir de variáveis cross-platform (*score* combinado, popularidade Spotify, seguidores, contagem de presença mensal), reportando AUC ROC e *feature importance*; (ii) *K-means* clustering [MacQueen 1967] com seleção automática de  $K \in \{2, \dots, 6\}$  pelo *silhouette score* [Rousseeuw 1987], agrupando artistas em perfis comportamentais sobre os ranks mensais; (iii) *Análise de Componentes Principais* [Pearson 1901, Hastie et al. 2009] (PCA) com 2 componentes, visualizando o espaço multidimensional de artistas e a separabilidade da classe *Call2Go*. Todas as análises empregaram *StandardScaler* e semente aleatória fixa (*seed* = 42) para garantir reprodutibilidade.

**Análise de confundidor.** Para verificar se a relação entre *Call2Go* e engajamento poderia ser artefato de um confundidor (artistas já populares no Spotify adotando *Call2Go* com mais frequência—i.e., prática *reativa* em vez de *preditiva*), aplica-se procedimento em dois níveis: (i) regressão logística binária ajustando  $\text{has\_any\_call2go\_or} \sim \text{popularity}_{\text{SP}} + \text{followers}_{\text{SP}}$  sobre os artistas Top-K com métricas Spotify com-

pletas, da qual se reportam os *odds ratios* ( $OR = e^\beta$ ) como medida descritiva de tamanho de efeito; (ii) estratificação dos artistas em quartis de popularidade Spotify, executando o teste  $H_2$  de Mann-Whitney U para visualizações YouTube versus *Call2Go* OR dentro de cada quartil. O modelo é ajustado com o `LogisticRegression` do `scikit-learn` [Pedregosa et al. 2011].

#### 4.5. Protocolo de Validação Cruzada

A validação adota **design adversarial** para maximizar o rigor metodológico. Em vez de amostrar aleatoriamente do corpus, foram selecionados 91 vídeos que desafiam especificamente o detector: casos limítrofes com redirecionadores de terceiros, emojis, URLs codificadas, textos ambíguos entre CTA e menção narrativa, e perfis de canal com formato incomum. A anotação foi conduzida às **cegas**: o anotador humano classificou cada vídeo sem visualizar a saída do sistema automatizado, eliminando o viés de confirmação presente em protocolos circulares.

As métricas reportadas são: acurácia, precisão, *recall*, F1-score e Kappa de Cohen com IC 95% via *bootstrap* ( $B = 2.000$  reamostras com semente fixa para reprodutibilidade) [Cohen 1960, Efron 1979]. A validação é conduzida em dois níveis independentes: **Nível Vídeo** (detector restrito à descrição textual) e **Nível Canal** (detector restrito ao perfil do canal). Esse design, que desacopla os dois níveis, permite identificar onde o sistema é forte e onde apresenta margens de melhoria, com maior valor diagnóstico do que uma avaliação combinada.

### 5. Resultados e Análises

Esta seção apresenta e discute os resultados: começa pela validação do detector ( $H_0/H_1$ ), segue para os testes das hipóteses  $H_2$  a  $H_4$  e a análise de confundidor, e encerra com as análises de aprendizado de máquina.

#### 5.1. Validação Cruzada do Detector ( $H_0/H_1$ )


A validação cruzada do instrumento de mensuração precede logicamente todas as análises subsequentes. Sobre os 91 vídeos adversariais com anotação às cegas, segundo a escala de Landis e Koch [Landis and Koch 1977]: **Nível Canal** alcançou acurácia 90,1% e  $\kappa = 0,80$  (concordância substancial), **rejeitando**  $H_0$  e validando o uso do detector como ferramenta analítica; **Nível Vídeo** obteve acurácia 82,4% e  $\kappa = 0,45$  (concordância moderada), não rejeitando  $H_0$  ao limiar de 85%. O resultado por nível é coerente com a prática observada: artistas inserem o *Call2Go* predominantemente no perfil do canal, não em cada descrição de vídeo. A métrica OR, que combina os dois níveis, compensa essa limitação e constitui o modo de operação adotado nas análises subsequentes.

#### 5.2. Distribuição das Detecções de *Call2Go*

A execução do detector sobre o corpus de 2.495 vídeos (Top-K com cobertura completa de 56/56 artistas) produz: **590 vídeos com *Call2Go* OR** (23,6%) e **88 vídeos com *Call2Go* AND** (3,5%). A decomposição por nível confirma que o canal é a fonte dominante (*scraping*), validando a imprescindibilidade desse módulo: a prática predominante é inserir o *link* no perfil do canal—válido para todos os vídeos—e não em cada descrição separadamente.

### 5.3. Análise Exploratória de Dados (EDA)

A análise exploratória confronta as distribuições de `view_count` sobre o universo Top-K ( $n = 1.493$  vídeos: 272 com *Call2Go* OR e 1.221 sem). Em ambos os grupos, a distribuição é assimétrica à direita, com cauda longa de vídeos virais (Figura 2).



**Figura 2. Boxplot de visualizações (log) entre vídeos com *Call2Go* OR e sem *Call2Go* no Top-K. A diferença de medianas (2,48M vs. 1,06M) é confirmada por  $H_2$ .**

A separação visual de medianas antecipa o achado quantitativo dos testes formais. A hipótese de que essa separação seja explicada exclusivamente pela popularidade pré-existente do artista (potencial variável confundidora) foi testada formalmente na subseção de Análise de Confundidor (Seção 5.5).

### 5.4. Testes de Hipótese $H_2$ e $H_3$

Os testes Mann-Whitney U [Mann and Whitney 1947] aplicados sobre o universo Top-K (56 artistas, 1.493 vídeos) produzem, para  $H_2$  (visualizações YouTube): OR ( $n = 272$  vs. 1.221,  $U = 188.018,5$ ,  $p < 0,001$ ) e AND ( $n = 44$  vs. 1.449,  $U = 40.543$ ,  $p = 0,001$ ), **rejeitando**  $H_0$  em ambas. Para  $H_3$  (popularidade Spotify), os testes não rejeitam  $H_0$ . A interpretação dos  $p$ -valores segue a recomendação atual da *American Statistical Association* [Wasserstein and Lazar 2016]: rejeição ou não rejeição de  $H_0$  deve ser complementada por discussão de tamanho de efeito e poder estatístico [Cohen 1988], evitando a transformação mecânica de um limiar arbitrário em conclusão substantiva. A mediana de visualizações em vídeos com *Call2Go* OR (2,48M) é mais que o dobro da observada em vídeos sem *Call2Go* (1,06M); para a métrica AND, mediana de 3,13M com vs. 1,17M sem—efeito de magnitude prática relevante.  $H_3$  não rejeitada sugere que o benefício do *Call2Go* se manifesta no engajamento local da plataforma de origem (YouTube *views*) sem se traduzir em ganho mensurável na métrica opaca de popularidade Spotify. A análise de confundidor descrita a seguir refina essa interpretação.

### 5.5. Análise de Confundidor (Popularidade Pré-existente)

A regressão logística [Hastie et al. 2009]  $\text{has\_any\_call2go\_or} \sim \text{popularity}_{\text{SP}} + \text{followers}_{\text{SP}}$  ( $N = 27$  artistas Top-K com dados disponíveis) produz *odds ratios*

praticamente iguais à unidade: o *odds ratio* da popularidade Spotify é  $OR = 1,003$  e o de seguidores é  $OR \approx 1,000$ . Como ambos são essencialmente 1 (efeito nulo na prática), o nível agregado de popularidade Spotify pré-existente *não* apresenta associação prática com a adoção de *Call2Go*; a hipótese de prática estritamente reativa não se sustenta em escala agregada.

A estratificação por quartil de popularidade (Tabela 1) revela, no entanto, um padrão heterogêneo importante:  $H_2$  é **altamente significativa** em Q1 (popularidade mais baixa,  $p < 0,001$ ) e **significativa** em Q4 (popularidade mais alta,  $p = 0,015$ ), mas permanece não significativa em Q2 e Q3 (faixas intermediárias). Essa distribuição sugere uma curva em “U” do efeito de *Call2Go*: artistas emergentes (Q1) parecem ganhar com a estratégia (talvez por amplificação relativa em audiências menores), bem como artistas de *topo* (Q4), enquanto os intermediários não exibem ganho mensurável. Trata-se de hipótese exploratória—a comparação envolve grupos desbalanceados e não controla por covariáveis adicionais (gravadora, gênero, fase de carreira).

**Tabela 1.**  $H_2$  (Mann-Whitney U, alternativa *greater*) estratificado por quartil de `popularitySP`.

| Quartil         | <i>n</i> com <i>Call2Go</i> | <i>n</i> sem | <i>U</i> | <i>p</i> | Decisão              |
|-----------------|-----------------------------|--------------|----------|----------|----------------------|
| Q1 (mais baixo) | 86                          | 104          | 6.784    | < 0,001  | <b>rejeita</b> $H_0$ |
| Q2              | 51                          | 115          | 1.007    | 1,0000   | n.s.                 |
| Q3              | 30                          | 103          | 1.685    | 0,2263   | n.s.                 |
| Q4 (mais alto)  | 33                          | 147          | 3.010    | 0,0154   | <b>rejeita</b> $H_0$ |

$\alpha = 0,05$ . Quartis definidos sobre `popularitySP` dos artistas com dados *Call2Go* no Top-K.

### 5.6. Análise Bidirecional YouTube ↔ Spotify


A análise bidirecional de Spearman dentro do Top-K ( $N = 56$ ,  $\alpha = 0,05$ ) revela correlações significativas em todas as direções entre as três plataformas: YT Views ↔ SP Popularidade ( $\rho = 0,442$ ,  $p = 0,0002$ ); YT Views ↔ SP Seguidores ( $\rho = 0,422$ ,  $p = 0,0004$ ); YT Views ↔ LFM Scrobbles ( $\rho = 0,439$ ,  $p = 0,0002$ ); SP Pop ↔ LFM Listeners ( $\rho = 0,663$ ,  $p < 0,001$ ); SP Seguidores ↔ LFM Scrobbles ( $\rho = 0,848$ ,  $p < 0,001$ ). Esses resultados evidenciam **convergência multiplataforma** dentro da elite ranqueada: artistas do Top-K tendem a apresentar performance correlacionada entre as três plataformas, ainda que apenas correlacional, não causal.

### 5.7. Análise Temporal: Defasagem YouTube vs. *Charts* Spotify ( $H_4$ )

A análise temporal é conduzida sobre 49 artistas com vídeos coletados e presença nos *charts* Spotify de Janeiro–Abril 2026. A defasagem (*lag*) é calculada como a diferença em dias entre a data do primeiro vídeo do artista no YouTube e sua data de entrada no *chart* Spotify BR. Valores negativos indicam que o YouTube precedeu o *chart*; valores positivos indicariam o contrário.

A mediana de `lag_any_days` é de **−637 dias** (IQR:  $[-1.214; -223]$ ), indicando que para a maioria dos artistas a atividade no YouTube precede a entrada nos *charts* em quase dois anos (45 de 49 artistas, 92%, têm o YouTube antecedendo o *chart*).

Para os 18 artistas com *Call2Go* confirmado antes da entrada no *chart*, a mediana de *lag\_call2go\_days* é de  $-514$  dias (IQR:  $[-1.051; -190]$ ).



**Figura 3. Defasagem temporal (dias) entre atividade no YouTube e entrada nos *charts* Spotify BR ( $n = 49$ ). Valores negativos indicam que o YouTube precede os *charts*; a mediana de  $-637$  dias evidencia o YouTube como palco antecedente ao sucesso nos *charts*.**


As correlações de Spearman entre janelas de atividade pré-entrada e desempenho nos *charts* ( $n = 49$ ,  $\alpha = 0,05$ ) indicam tendência positiva mas não significativa para o volume de publicações nos 30 dias anteriores à entrada no *chart* ( $\rho = 0,242$ ,  $p = 0,093$ ); as variáveis específicas de *Call2Go* pré-*chart* ( $\rho = 0,086$ ,  $p = 0,555$ ) também não apresentam correlação significativa com o desempenho subsequente. A direcionalidade temporal permanece clara—YouTube precede *charts*—ainda que a intensidade da atividade pré-entrada não constitua, por si só, preditor significativo de *score* combinado neste universo.

## 5.8. Convergência Multiplataforma e Análises de Aprendizado de Máquina

A integração com o Last.fm como terceira fonte independente reforça a convergência: a correlação Seguidores Spotify  $\leftrightarrow$  Scrobble Last.fm ( $\rho = 0,848$ ,  $p < 0,001$ ) e Popularidade Spotify  $\leftrightarrow$  Listeners Last.fm ( $\rho = 0,663$ ,  $p < 0,001$ ) confirmam consistência entre plataformas. Auditoria automatizada via Playwright [Microsoft 2024] verificou 0 *links* reversos em quatro direções (Spotify/Last.fm  $\rightarrow$  YouTube/Spotify), corroborando que o fluxo de *links* explícitos *Call2Go* é estruturalmente unidirecional YouTube  $\rightarrow$  Spotify.

**Análises de Aprendizado de Máquina (*scikit-learn*).** Para complementar os testes estatísticos clássicos, aplicam-se três técnicas sobre o universo Top-K. Um classificador *Random Forest* [Breiman 2001] ( $n_{\text{trees}} = 200$ ) com validação cruzada estratificada de 5 *folds* predizendo *has\_call2go\_or* a partir de cinco variáveis *cross-platform* obtém  $AUC = 0,567 \pm 0,207$  (acurácia  $0,632 \pm 0,091$ ). O intervalo cruza  $AUC = 0,5$  e o desvio entre *folds* é elevado, indicando **poder preditivo limitado** para o tamanho de amostra disponível ( $n = 38$  artistas com *features* completas); o resultado deve ser lido como caracterização de *importance* relativa entre variáveis, não como classificador operacional. Ainda assim, a *feature importance* é informativa: *score\_spotify\_normalized* emerge como a mais relevante (0,278), seguida por *score\_youtube\_normalized* (0,270)

e `score_combined` (0,264). O agrupamento via *K-means* [MacQueen 1967] sobre os *ranks* mensais e o *score* combinado, com seleção automática de *K* pelo *silhouette score* [Rousseeuw 1987], identifica  $K^* = 6$  (*silhouette* = 0,427) perfis comportamentais distintos, oferecendo uma taxonomia derivada empiricamente em substituição a categorias *ad hoc*. A Análise de Componentes Principais [Pearson 1901, Hastie et al. 2009] projeta os 56 artistas em 2D explicando 78,8% da variância acumulada (PC1 = 54,2%, PC2 = 24,5%), permitindo visualização integrada do espaço multidimensional de métricas. Esses resultados convergem na direção de que os *scores* obtidos via *Reciprocal Rank Fusion* são os sinais mais informativos disponíveis para inferir a probabilidade de adoção de *Call2Go* por um artista no corpus analisado.



**Figura 4.** Análises de *machine learning* sobre o Top-K via *scikit-learn* [Pedregosa et al. 2011]: (esq.) PCA 2D com 78,8% de variância acumulada; (dir.) *feature importance* do Random Forest (5-fold CV), com os *scores* normalizados de Spotify e YouTube dominando.

## 5.9. Evolução Mensal (Janeiro–Abril)

A janela quadrimestral revela renovação significativa do elenco: 85 artistas primários distintos no Spotify em janeiro e 137 em abril; no YouTube, 101 em janeiro e 98 em abril. A taxonomia estrutural de presença (RRF) classifica 18,5% dos artistas como *persistent* (presentes nos quatro meses) no Spotify e 11,6% no YouTube; padrões *new* e *exit* somam 24,7% no YouTube versus 12,7% no Spotify, refletindo turnover mais alto na plataforma de vídeo. Movimentos extremos no *ranking* Spotify entre janeiro e abril ilustram a volatilidade: subidas máximas de *MC Meno K* (72 → 9,  $\Delta = +63$ ), *Zé Neto & Cristiano* (66 → 8, +58) e *Mc Jacaré* (49 → 5, +44); quedas máximas de *Yasmin Sensação* (29 → 168, -139), *DJ Zigao* (42 → 171, -129) e *AgroPlay* (11 → 118, -107).

## 6. Conclusões e Trabalhos Futuros

Este trabalho investiga empiricamente a efetividade da estratégia *Call2Go* como mecanismo *cross-platform* na indústria musical brasileira [IFPI 2023, Pró-Música Brasil 2026], em resposta a uma lacuna empírica na literatura sobre dinâmicas de distribuição digital [Aguiar and Waldfogel 2021, Wlömert and Papies 2016]. O estudo adota uma metodologia baseada em **Reciprocal Rank Fusion** [Cormack et al. 2009] sobre 276 artistas primários nos *charts* de Janeiro–Abril 2026, com seleção do Top-K = 56 (cobrindo 82,9% do *score* acumulado). Os principais achados são sintetizados a seguir.

**Confiabilidade do detector ( $H_0/H_1$ ):** a validação adversarial às cegas com 91 vídeos revela  $\kappa = 0,80$  no nível canal (substancial; acurácia 90,1%), rejeitando  $H_0$  para esse nível e validando a abordagem. No nível vídeo,  $\kappa = 0,45$  e acurácia 82,4% não rejeitam  $H_0$ , evidenciando a limitação do detector isolado na descrição individual—e justificando a arquitetura bicamada com operador OR como modo primário de operação. O sistema é determinístico, interpretável e auditável, com suíte de 95 testes unitários cobrindo as oito regras R1–R8 e a heurística *strict*.

**Impacto no engajamento ( $H_2$  e  $H_3$ ):** com cobertura completa do Top-K (56 artistas, 1.493 vídeos), os testes Mann-Whitney U [Mann and Whitney 1947] **rejeitam**  $H_0$  para as visualizações do YouTube em ambas as métricas (OR:  $U = 188.018,5$ ,  $p < 0,001$ ; AND:  $U = 40.543$ ,  $p = 0,001$ ). A mediana de *views* nos vídeos com *Call2Go* OR (2,48M) é mais que o dobro da observada nos sem *Call2Go* (1,06M)—tamanho de efeito prático [Cohen 1988] relevante e estatisticamente significativo [Wasserstein and Lazar 2016]. A popularidade do Spotify, em contraste, não rejeita a nulidade, sugerindo que o efeito é específico ao YouTube e não se transfere para a métrica algorítmica de *streaming*, achado coerente com a literatura sobre fragmentação de audiências *cross-platform* [Napoli 2010, Wlömert and Papies 2016]. O teste de confundidor descarta a hipótese forte de prática estritamente reativa: a popularidade Spotify pré-existente não apresenta associação prática com a adoção de *Call2Go* (regressão logística [Hastie et al. 2009], *odds ratios*  $\approx 1$  para popularidade e seguidores). A estratificação por quartil revela um **padrão em forma de U**:  $H_2$  é altamente significativa em Q1 ( $p < 0,001$ ) e Q4 ( $p = 0,015$ ), permanecendo n.s. nos quartis intermediários, sugerindo que o efeito opera nos extremos da distribuição de popularidade.

**Convergência *cross-platform* e direcionalidade ( $H_4$ ):** correlações de Spearman dentro do Top-K são significativas em todas as direções entre as três plataformas ( $\rho \approx 0,44$  entre YouTube Views e Spotify Popularity,  $p = 0,0002$ ;  $\rho = 0,848$  entre Seguidores Spotify e Scrobble Last.fm), evidenciando convergência multiplataforma na elite ranqueada. Auditoria automatizada verifica 0 *links* reversos em quatro direções, confirmando direcionalidade estrutural YouTube  $\rightarrow$  Spotify do fluxo *Call2Go*. A análise temporal indica que o YouTube precede a entrada nos *charts* Spotify em mediana de  $-637$  dias ( $H_4$  confirmada quanto à direcionalidade); a intensidade da atividade pré-*chart* ( $\rho = 0,242$ ,  $p = 0,093$ ) apresenta tendência positiva mas não significativa neste universo.

**Contribuições metodológicas:** o pipeline ETL de 20 etapas é reproduzível e determinístico (95 testes cobrem o detector); o uso de *Reciprocal Rank Fusion* [Cormack et al. 2009] mensal evita o *viés de seleção de sucesso*; e técnicas de aprendizado de máquina [Breiman 2001, MacQueen 1967, Pearson 1901, Pedregosa et al. 2011] agregam predição, agrupamento e visualização sobre o Top-K. Os achados confirmam, para o mercado brasileiro, a hipótese do vídeo como funil para o *streaming* [Wlömert and Papies 2016], matizando-a ao revelar dependência de regime de popularidade.

**Limitações:** o universo Top-K reflete artistas com visibilidade pública nos *charts*; as métricas do Spotify são *snapshot* transversal (sem causalidade) e o campo *popularity* é opaco; o Kappa de vídeo (0,45) indica margem de melhoria do detector na descrição individual; a heterogeneidade observada na estratificação por quartil (Tabela 1) é exploratória—grupos desbalanceados, sem controle por covariáveis adicionais; a janela

quadrimestral limita a análise temporal a defasagens curtas em relação ao histórico de cada artista no YouTube.

**Trabalhos futuros:** a análise temporal pode ser enriquecida com dados longitudinais de *streams* semanais no Spotify, viabilizando modelagem de causalidade de Granger; o detector pode ser estendido com modelos de linguagem (*transformers*) para chamadas em formatos não estruturados; e o pipeline é transferível para outros pares de plataformas (e.g., TikTok → Spotify) com atualização trimestral da base.

## Declaração de Uso de Inteligência Artificial

Em conformidade com o Regulamento de TCC PUC Minas 2025, foram utilizadas ferramentas de IA generativa como apoio à redação, organização do texto e geração de *pseudocódigo*. Dados primários, implementação, análises estatísticas e interpretação científica são originais e de responsabilidade exclusiva do autor.

## Referências

- Aguiar, L. and Waldfogel, J. (2021). Platforms, power, and promotion: Evidence from Spotify playlists. *The Journal of Industrial Economics*, 69(3):653–691.
- Audioscrobbler (2024). Last.fm API — music data for developers. Last.fm Developer Documentation. Acesso em: 19 abr. 2026.
- Bouchardet, C. C., Gonçalves, K. C., Passaro, L., Almeida, J. M., and Marques-Neto, H. T. (2025). Call2Go: A cross-platform strategy of kids online social media influencers. In *Proceedings of the Brazilian Symposium on Multimedia and the Web (WebMedia)*, pages 112–120, Porto Alegre, RS, Brasil. Sociedade Brasileira de Computação (SBC).
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Celma, Ò. (2010). *Music Recommendation and Discovery: The Long Tail, Long Fail, and Long Play in the Digital Music Space*. Springer, Berlin.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46.
- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, 2 edition.
- Cormack, G. V., Clarke, C. L. A., and Buettcher, S. (2009). Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd Annual International ACM SIGIR Conference*, pages 758–759. ACM.
- Covington, P., Adams, J., and Sargin, E. (2016). Deep neural networks for YouTube recommendations. *Proceedings of the 10th ACM Conference on Recommender Systems*, pages 191–198.
- Efron, B. (1979). Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1):1–26.
- Friedl, J. E. F. (2006). *Mastering Regular Expressions*. O’Reilly Media, 3 edition.
- Google (2024). YouTube Data API v3 — reference. Google Developers. Acesso em: 28 mar. 2026.

- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, 2 edition.
- IBGE (2026). Pesquisa nacional por amostra de domicílios contínua — módulo de tecnologia da informação e comunicação (pnad contínua tic). Instituto Brasileiro de Geografia e Estatística. <https://www.ibge.gov.br/>. Acesso em: 06 mai. 2026.
- IFPI (2023). Global music report 2023. International Federation of the Phonographic Industry. Acesso em: 28 mar. 2026.
- Krippendorff, K. (2004). *Content Analysis: An Introduction to Its Methodology*. Sage Publications, Thousand Oaks, 2 edition.
- Landis, J. R. and Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174.
- MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, volume 1, pages 281–297.
- Mann, H. B. and Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1):50–60.
- McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, pages 56–61.
- Microsoft (2024). Playwright — fast and reliable end-to-end testing for modern web apps. Playwright Documentation. Acesso em: 21 abr. 2026.
- Mitchell, R. (2018). *Web Scraping with Python: Collecting More Data from the Modern Web*. O'Reilly Media, 2 edition.
- Napoli, P. M. (2010). *Audience Evolution: New Technologies and the Transformation of Media Audiences*. Columbia University Press, New York.
- Pearson, K. (1901). On lines and planes of closest fit to systems of points in space. *Philosophical Magazine*, 2(11):559–572.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- Pró-Música Brasil (2026). Pró-música brasil — associação representativa do mercado fonográfico brasileiro. <https://pro-musicabr.org.br/>. Entidade representativa da indústria fonográfica brasileira. Acesso em: 06 mai. 2026.
- Python Software Foundation (2024). Python 3.12 documentation. [python.org](https://python.org). Acesso em: 28 mar. 2026.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20:53–65.
- Salganik, M. J. (2019). *Bit by Bit: Social Research in the Digital Age*. Princeton University Press, Princeton.

- Schedl, M., Gómez, E., and Urbano, J. (2014). Music information retrieval: Recent developments and applications. *Foundations and Trends in Information Retrieval*, 8(2–3):127–261.
- Spearman, C. (1904). The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1):72–101.
- Spotify (2024). Spotify Web API — reference. Spotify for Developers. Acesso em: 28 mar. 2026.
- Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17:261–272.
- Wasserstein, R. L. and Lazar, N. A. (2016). The ASA statement on  $p$ -values: Context, process, and purpose. *The American Statistician*, 70(2):129–133.
- Wlömert, N. and Papies, D. (2016). On-demand streaming services and music industry revenues — insights from Spotify’s market entry. *International Journal of Research in Marketing*, 33(2):314–327.