Colinha do TCC

Explicação Completa em Linguagem Simples

---

*Detecção Automatizada de Estratégias **Call2Go**:*
Pipeline Cross-Platform para a Indústria Musical Brasileira

Lucas Fiori Magalhães Machado
Bacharelado em Ciência da Computação — PUC Minas

29 de abril de 2026

Este documento é um guia de bolso para entender e explicar o TCC.
Cada número, gráfico e teste estatístico está explicado em linguagem simples.

Não é o artigo final — é a sua cola pessoal.

Sumário

1 O que é esse TCC? 3

2 O que é Call2Go? 3

3 De onde vieram os dados? 4

3.1 Quem foram os artistas? 4

3.2 Quantos vídeos foram analisados? 4

3.3 De onde vieram os dados de cada plataforma? 4

4 O pipeline: os 15 passos do processo 5

5 Como o detector funciona? 6

5.1 Dois níveis de detecção 6

5.2 As 4 regras de busca no nível vídeo 7

5.3 Filtro anti-falsos-positivos 7

5.4 Lógica OR e AND 7

6 O que o detector encontrou: as detecções 8

7 O Boxplot: comparando visualizações 8

7.1 O que é um boxplot? 8

7.2 O que o gráfico da Figura 1 mostra? 9

8 Testes estatísticos: hipóteses H2 e H3 9

8.1 O que são H2 e H3? 9

8.2 O que é o teste de Mann-Whitney U? 10

8.3 Resultados dos testes 10

9 Correlação bidirecional: YouTube ↔ Spotify 11

9.1 O que é correlação de Spearman? 11

9.2 Por que a análise foi “bidirecional”? 11

9.3 Resultados 12

10 Análise temporal: o YouTube precede os charts **13**

10.1 O que é o "lag" (defasagem)? 13

10.2 Por que só 39 artistas? 13

10.3 Resultados principais 14

10.4 Os preditores temporais (Tabela de correlações) 14

11 Last.fm e auditoria de voltas **15**

11.1 O que é o Last.fm nesse contexto? 15

11.2 Correlação Last.fm × Spotify 15

11.3 Call2Go afeta métricas no Last.fm? 15

11.4 O que é a "auditoria de voltas"? 15

12 A validação do detector **16**

12.1 O que é a validação cruzada do detector? 16

12.2 O que é a Matriz de Confusão? 16

12.3 O que é o Kappa de Cohen (κ)? 17

12.4 Resultados da validação 17

13 O que concluímos? (H0 a H4 em linguagem direta) **18**

14 Glossário rápido **19**

1 O que é esse TCC?

O TCC estuda uma prática muito comum na indústria musical brasileira chamada *Call2Go*. Em resumo, a pesquisa faz duas coisas principais:

1. **Cria uma ferramenta automática** capaz de detectar se um artista está usando essa estratégia em seus vídeos do YouTube.
2. **Testa estatisticamente** se essa estratégia faz diferença real: artistas que usam Call2Go ganham mais visualizações? Ficam mais populares no Spotify?

O foco central do trabalho **não** é sobre música, artistas ou o mercado fonográfico em si. O que realmente importa é: **"a ferramenta que criamos é confiável?"** Os artistas são apenas o banco de dados utilizado para testar essa ferramenta.

Por que isso importa? Sem uma ferramenta confiável, qualquer conclusão sobre Call2Go seria suspeita. Então, antes de analisar qualquer dado, foi necessário garantir que o detector funcionava corretamente — e isso foi feito por meio de uma validação com humanos.

2 O que é Call2Go?

Imagine que você está assistindo a um clipe no YouTube. Lá na descrição do vídeo, o artista coloca algo parecido com:

> *"Ouça agora no Spotify: https://open.spotify.com/..."*
> *"Disponível no Spotify ↓ bit.ly/MinhaMusica"*
> *"Stream agora no Spotify!"*

Isso é um *Call2Go*: uma **chamada de ação** (*call-to-action*) que leva o ouvinte do YouTube diretamente para o Spotify.

Por que os artistas fazem isso? A lógica é simples: o YouTube é gratuito, tem alcance enorme e qualquer pessoa pode acessar. Já o Spotify paga diretamente ao artista por cada *stream*. Então faz sentido usar o YouTube como vitrine para converter fãs em ouvintes pagos/recorrentes no Spotify.

O Call2Go pode aparecer em dois lugares diferentes:

- **Na descrição do vídeo**: um link ou texto direto no campo de descrição do YouTube (o texto que aparece abaixo do vídeo).
- **Na bio do canal**: na aba "Sobre" do canal do artista no YouTube, onde ele pode colocar links externos para outras plataformas.

O TCC verifica os **dois lugares** e combina as detecções de duas formas:

- **OR**: Call2Go detectado no vídeo **OU** no canal (qualquer um dos dois basta).
- **AND**: Call2Go detectado no vídeo **E** no canal ao mesmo tempo (os dois precisam estar presentes).

3 De onde vieram os dados?

3.1 Quem foram os artistas?

Foram selecionados **67 artistas brasileiros** que apareceram simultaneamente nos dois rankings abaixo durante o primeiro trimestre de 2026 (Q1 2026 = janeiro, fevereiro e março de 2026):

- **Spotify Top 200 Brasil**: ranking das 200 músicas mais ouvidas no Spotify Brasil por semana.
- **YouTube Top 100 Brasil**: ranking dos 100 vídeos mais assistidos no YouTube Brasil por semana.

O critério foi aparecer em pelo menos uma semana das **13 semanas** do Q1 2026 nos **dois** rankings ao mesmo tempo. Isso é chamado de *persistência cross-platform*: o artista é relevante nas duas plataformas.

A escolha de usar os dois rankings juntos foi proposital: só interessam artistas que realmente usam as duas plataformas de forma ativa, porque o estudo compara YouTube com Spotify.

3.2 Quantos vídeos foram analisados?

Para cada um dos 67 artistas, foram coletados os **30 vídeos mais visualizados** de cada canal do YouTube. O total ficou em:

$$67 \text{ artistas} \times \approx 30 \text{ vídeos} = \mathbf{1.641 \text{ vídeos}}$$

Obs.: O número não é exatamente 2.010 (67 × 30) porque alguns canais tinham menos de 30 vídeos disponíveis no momento da coleta.

3.3 De onde vieram os dados de cada plataforma?

- **YouTube** — via YouTube Data API v3 (ferramenta oficial do Google). Foram coletadas as descrições dos vídeos, número de visualizações e data de publicação de cada vídeo.
- **Spotify** — via Spotify Web API (ferramenta oficial do Spotify). Coletou-se a *popularidade* (índice de 0 a 100 que o próprio Spotify calcula com base em recência e frequência de streams) e o número de seguidores de cada artista. O snapshot (foto dos dados) foi tirado em 22 de abril de 2026.
- **Last.fm** — via Last.fm API. O Last.fm é uma rede social de música que registra automaticamente o que as pessoas ouvem (*scrobbling*). Foram coletados: ouvintes mensais, scrobbles (total de reproduções registradas) e presença nos charts brasileiros do Last.fm. Serve como uma **terceira plataforma independente** para cruzar e validar os dados.

- **Scraping dos canais** — a aba "Sobre" de cada canal do YouTube tem links externos, mas a API oficial do YouTube **não fornece** esses links. Por isso foi necessário usar um *scraper*: um programa que acessa a página do canal diretamente, lê o código HTML e extrai os links ali presentes.

4 O pipeline: os 15 passos do processo

Um *pipeline* é uma sequência de etapas automatizadas, onde a saída de cada etapa é a entrada da próxima — como uma linha de produção de fábrica. O pipeline do TCC tem **15 etapas** no total, roda do início ao fim em aproximadamente **40 segundos** e gera **30 artefatos** verificáveis (arquivos de saída auditáveis).

Bloco 1 — Coleta de Dados (Etapas 1–5)

Etapa 1 — Lista de artistas
Lê um arquivo CSV com os 67 artistas selecionados manualmente dos charts e os cadastra no sistema como ponto de partida de tudo.

Etapa 2 — Coleta YouTube
Para cada artista, acessa o canal do YouTube via API e baixa os dados dos 30 vídeos mais visualizados: título, descrição completa, número de visualizações e data de publicação.

Etapa 3 — Coleta Spotify
Para cada artista, consulta a API do Spotify e salva dois valores: popularidade (0–100) e número de seguidores.

Etapa 4 — Coleta Last.fm
Para cada artista, consulta a API do Last.fm e salva: ouvintes mensais, total de scrobbles e se o artista está nos charts brasileiros do Last.fm.

Etapa 5 — Scraping de canais
Acessa a aba "Sobre" de cada canal do YouTube via scraper e extrai os links externos ali listados (por exemplo, link do Spotify na bio do canal).

Bloco 2 — Detecção e Banco de Dados (Etapas 6–7)

Etapa 6 — Detecção Call2Go
Aplica o motor de detecção (explicado na Seção 5) sobre as descrições dos vídeos e sobre os links dos canais. Gera para cada vídeo: detectou no vídeo? detectou no canal? resultado OR? resultado AND?

Etapa 7 — Data Warehouse
Salva todos os dados coletados e as detecções em um banco de dados SQLite com **6 tabelas** organizadas em *star schema* (formato padrão para análises de dados, com uma tabela central e tabelas de apoio ao redor).

Bloco 3 — Análises Estatísticas (Etapas 8–12)

Etapa 8 — EDA (Análise Exploratória)
Visão geral dos dados: distribuições, médias, boxplots. É a etapa de "olhar os dados" antes de qualquer teste formal.

Etapa 9 — Mann-Whitney
Testa as hipóteses H2 e H3: Call2Go afeta visualizações no YouTube? Afeta popularidade no Spotify?

Etapa 10 — Cross-Platform
Analisa a relação estatística entre as métricas do YouTube e do Spotify por artista.

Etapa 11 — Last.fm Bridge
Cruza os dados do Last.fm com YouTube e Spotify, usando o Last.fm como terceira fonte independente.

Etapa 12 — Validação Bidirecional
Analisa a correlação nos dois sentidos: YouTube→Spotify e Spotify→YouTube. Qual plataforma influencia a outra?

Bloco 4 — Análise Temporal (Etapas 13–15)

Etapa 13 — Datas Spotify
Recupera quando cada artista apareceu pela primeira vez nos charts do Spotify, para poder calcular a diferença de tempo em relação ao YouTube.

Etapa 14 — Ranking Fusion
Cria um score combinado cruzando as posições dos artistas nos rankings de YouTube, Spotify e Last.fm simultaneamente.

Etapa 15 — Análise Temporal
Calcula a defasagem de tempo (lag) entre a atividade no YouTube e a entrada nos charts do Spotify, e testa se essa defasagem é correlacionada com o desempenho nos charts.

Etapa adicional — Validação Independente

Fora do pipeline automatizado, foi feita uma validação manual com **91 vídeos adversariais** (casos propositalmente difíceis de classificar). Um humano analisou cada vídeo **sem saber** o que o detector tinha classificado (*anotação às cegas* = sem viés de confirmação). As respostas do humano foram comparadas com as do detector para medir a confiabilidade.

5 Como o detector funciona?

O detector é um sistema de *busca de texto inteligente* baseado em *regex* (*expressões regulares*). Pense num regex como uma pesquisa avançada — tipo o Ctrl+F do Word, mas com regras muito mais sofisticadas que entendem padrões, variações e contexto.

5.1 Dois níveis de detecção

O detector opera em **dois lugares independentes** em paralelo:

- **Nível Vídeo**: analisa a **descrição de cada vídeo** do YouTube (o texto que aparece abaixo do vídeo).
- **Nível Canal**: analisa os **links externos** listados na aba "Sobre" do canal e também a bio do canal.

5.2 As 4 regras de busca no nível vídeo

Dentro da descrição de cada vídeo, o sistema procura 4 tipos de padrões:

Regra R1 — Links diretos do Spotify Procura pelos domínios `open.spotify.com`, `spoti.fi` ou `sptfy.com` no texto. Se encontrar qualquer um desses, é Call2Go. Exemplo: *"https://open.spotify.com/album/abc123"*.

Regra R2 — Links curtos com rótulo "Spotify" Procura por links encurtados (`bit.ly`, `lnk.to`, etc.) que estejam a menos de 50 caracteres da palavra "spotify" no texto. Exemplo: *"Spotify: bit.ly/MinhaFaixa"* — o "bit.ly" e o "Spotify" estão próximos, então é Call2Go.

Regra R3 — Token "Spotify" na própria URL Procura por URLs que tenham a palavra *spotify* ou *sptfy* dentro do próprio endereço (ex: *"linkr.to/spotify-artista"*).

Regra R4 — Chamadas verbais sem link Procura por frases em português como *"ouça no Spotify"*, *"disponível no Spotify"* ou *"stream agora no Spotify"* — mesmo sem nenhum link. Captura a intenção de direcionar o ouvinte mesmo quando o artista só escreveu o texto sem colocar URL.

5.3 Filtro anti-falsos-positivos

Antes de aplicar qualquer regra, o texto passa por um **filtro** que descarta frases que mencionam o Spotify sem intenção de direcionar o ouvinte. Exemplos de frases que seriam **ignoradas**:

- *"#1 no Spotify Brasil"* (apenas falando sobre uma posição em ranking)
- *"500 milhões de plays no Spotify"* (apenas mostrando estatística)

Sem esse filtro, esses casos seriam detectados erroneamente como Call2Go.

5.4 Lógica OR e AND

O sistema combina os resultados dos dois níveis de duas formas:

- **OR (métrica primária)**: o vídeo é marcado como Call2Go se **o vídeo OU o canal** tiver Call2Go. Basta um dos dois ter. Captura qualquer uso da estratégia, mesmo que parcial.
- **AND (métrica secundária)**: o vídeo é marcado como Call2Go somente se **o vídeo E o canal** tiverem Call2Go ao mesmo tempo. Captura a forma mais completa e intencional da estratégia.

6 O que o detector encontrou: as detecções

Após rodar o detector sobre os 1.641 vídeos, estes foram os resultados:

Nível / Métrica	Vídeos	%
Detecção no vídeo (descrição)	196	11,9%
Detecção no canal (bio/links)	410	25,0%
OR — vídeo OU canal (métrica principal)	**518**	**31,6%**
AND — vídeo E canal simultaneamente	88	5,4%
Sem Call2Go (OR)	1.123	68,4%
Total	**1.641**	**100%**

Como interpretar cada linha:

- **196 vídeos (11,9%)** tinham Call2Go detectado **apenas na descrição do vídeo** — o artista colocou o link ou a chamada na descrição de cada vídeo individualmente.
- **410 vídeos (25,0%)** tinham Call2Go detectado **pelo canal** — significa que o canal do artista tem link do Spotify na aba "Sobre", e todos os vídeos desse canal herdam essa detecção.
- **518 vídeos (31,6%)** têm Call2Go no sentido OR: quase **1 em cada 3 vídeos** do corpus tem alguma forma da estratégia. Esta é a métrica principal.
- **88 vídeos (5,4%)** têm AND: o artista colocou Call2Go nos **dois lugares** ao mesmo tempo. É a forma mais intencional e completa da estratégia.
- **1.123 vídeos (68,4%)** **não** têm Call2Go em lugar nenhum.

Observação importante: o canal é a fonte dominante de detecção (25%) comparado ao vídeo (11,9%). Isso faz sentido: é muito mais prático para o artista colocar o link de Spotify uma vez na bio do canal do que escrever em cada vídeo individualmente.

7 O Boxplot: comparando visualizações

7.1 O que é um boxplot?

Um boxplot é um gráfico que resume como os valores estão distribuídos num grupo. Cada elemento do gráfico tem um significado:

- **A caixa (retângulo)**: representa onde ficam os 50% do meio dos dados. A borda de baixo é o 25º percentil; a borda de cima é o 75º percentil.
- **A linha dentro da caixa**: é a **mediana** — o valor central (metade dos dados fica acima, metade abaixo).
- **Os "fios" (whiskers)**: estendem até os valores mais extremos que ainda são considerados normais.
- **Os pontos fora dos fios**: são outliers (valores atípicos muito acima ou abaixo da maioria).

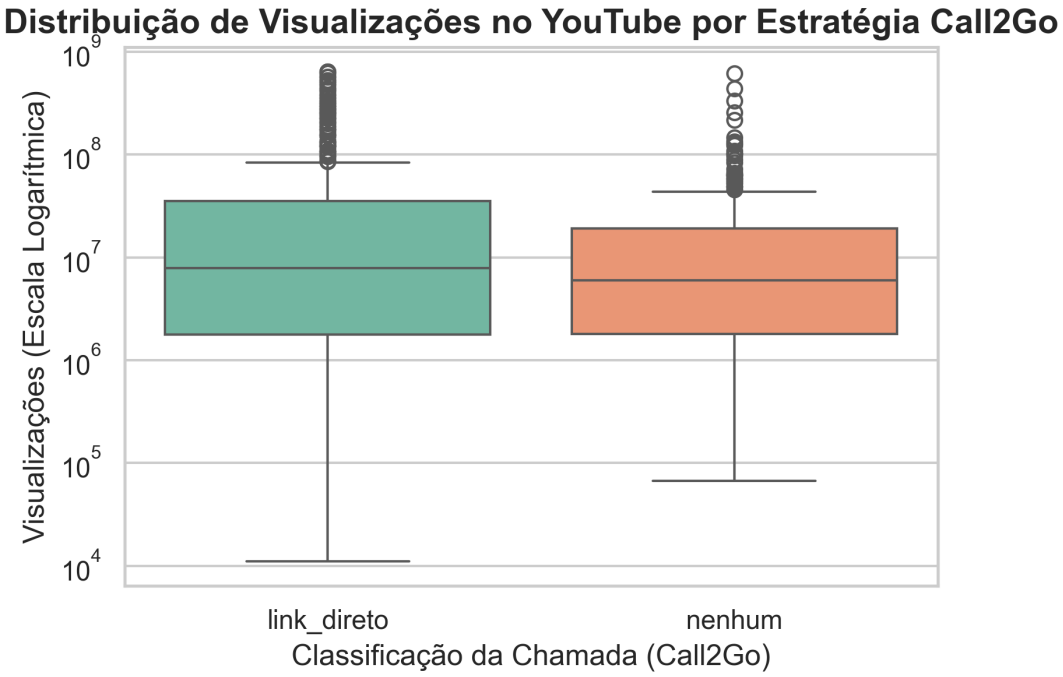

Figura 1: Boxplot comparativo de visualizações (escala log) entre vídeos **com** Call2Go OR ($n = 518$) e **sem** Call2Go ($n = 1.123$).

7.2 O que o gráfico da Figura 1 mostra?

O gráfico compara dois grupos lado a lado:

- **Grupo esquerdo**: vídeos **com** Call2Go OR (518 vídeos)
- **Grupo direito**: vídeos **sem** Call2Go (1.123 vídeos)

O eixo Y (vertical) está em **escala logarítmica**: cada traço representa 10 vezes mais visualizações que o anterior. Isso é necessário porque as visualizações variam enormemente (de alguns milhares até centenas de milhões).

Conclusão visual: As duas caixas estão quase na mesma altura. As medianas dos dois grupos são muito próximas. Isso já mostrava visualmente que vídeos com e sem Call2Go têm basicamente o mesmo desempenho em visualizações. Os testes estatísticos da próxima seção confirmaram isso formalmente.

8 Testes estatísticos: hipóteses H2 e H3

8.1 O que são H2 e H3?

- **H2**: Vídeos com Call2Go têm **mais visualizações** no YouTube do que vídeos sem Call2Go?
- **H3**: Artistas com mais Call2Go têm **maior popularidade** no Spotify?

8.2 O que é o teste de Mann-Whitney U?

O Mann-Whitney U é um **teste estatístico** para comparar se dois grupos são diferentes. Funciona assim: pega todos os valores dos dois grupos, coloca em ordem crescente e verifica se um grupo tende a ocupar posições maiores que o outro de forma consistente.

A grande vantagem é que ele **não exige** que os dados sigam uma distribuição normal (a famosa "curva de sino"). Como as visualizações de vídeos são muito assimétricas (poucos vídeos com centenas de milhões, muitos com apenas alguns mil), o Mann-Whitney é o teste mais adequado.

O resultado principal é o *valor-p* (p-value), que responde à pergunta: *"Qual a probabilidade de eu observar essa diferença entre os grupos simplesmente por acaso, mesmo que na realidade não exista diferença nenhuma?"*

- Se $p < 0{,}05$: resultado **estatisticamente significativo** — a diferença é real e provavelmente não é acaso.
- Se $p \geq 0{,}05$: **sem evidência de diferença real** — a diferença poderia ser apenas variação aleatória.

O valor U em si é a estatística do teste (quantas vezes um valor de um grupo foi maior que um valor do outro). É um número auxiliar; o que importa para a conclusão é o p.

8.3 Resultados dos testes

Hipótese	Métrica	Grupos (n)	U	p	Conclusão
H2: Call2Go → views YT	OR	518 vs. 1.123	280.705	0,872	sem efeito
H2: Call2Go → views YT	AND	88 vs. 1.553	73.010	0,140	sem efeito
H3: Call2Go → pop. SP	OR	(cruzado)	—	1,000	sem efeito
H3: Call2Go → pop. SP	AND	(cruzado)	—	0,998	sem efeito

Como ler cada linha:

- **H2, OR, YouTube** ($U = 280.705$, $p = 0{,}872$): Comparamos 518 vídeos com Call2Go contra 1.123 sem Call2Go. O $p = 0{,}872$ significa que há **87,2%** de chance de essa "diferença" aparecer simplesmente por acaso. Conclusão: **não há evidência de que o Call2Go aumenta visualizações**.
- **H2, AND, YouTube** ($U = 73.010$, $p = 0{,}140$): Mesmo resultado para a métrica AND. $p = 0{,}14$ ainda está bem acima de 0,05. Sem efeito.
- **H3, OR, Spotify** ($p = 1{,}000$): Este é o valor mais extremo possível de "não tem diferença nenhuma". Artistas com e sem Call2Go têm popularidade no Spotify **praticamente idêntica**.
- **H3, AND, Spotify** ($p = 0{,}998$): Praticamente o mesmo. Sem efeito.

Resumo: Nenhum dos 4 testes encontrou evidência estatística de que usar Call2Go faz diferença nas métricas de engajamento. Isso **não** significa que o Call2Go é inútil — significa que, com os dados disponíveis, não foi possível provar que ele faz diferença.

9 Correlação bidirecional: YouTube ↔ Spotify

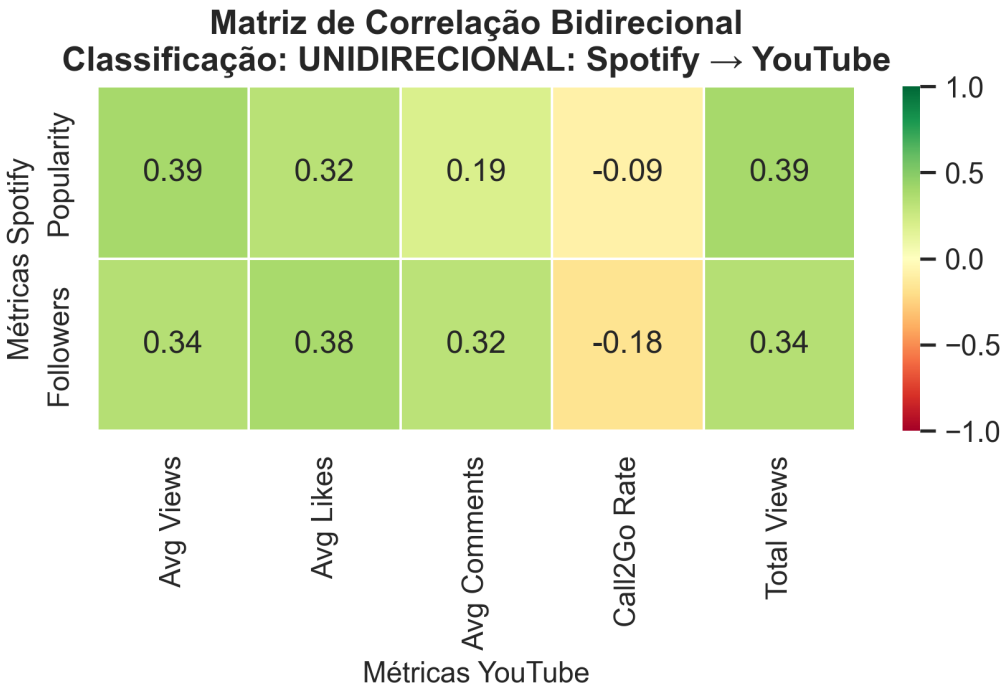

Figura 2: Matriz de correlação bidirecional (Spearman) entre métricas YouTube e Spotify ($N = 67$ artistas). Cores quentes = correlação alta; cores frias = correlação baixa.

9.1 O que é correlação de Spearman?

Correlação mede o quanto duas variáveis "andam juntas". O coeficiente ρ ("rô") de Spearman varia de -1 a $+1$:

- $\rho = +1$: correlação perfeita positiva (quando um sobe, o outro sempre sobe junto).
- $\rho = 0$: sem correlação (os dois não têm relação).
- $\rho = -1$: correlação perfeita negativa (quando um sobe, o outro sempre desce).

Por que Spearman (e não Pearson)? O Spearman usa as **posições** (rankings) dos valores em vez dos valores brutos. Isso é mais robusto quando os dados têm distribuições muito assimétricas, que é justamente o caso de visualizações do YouTube.

9.2 Por que a análise foi "bidirecional"?

A análise foi feita nos dois sentidos para descobrir se a influência vai de YouTube para Spotify, de Spotify para YouTube, ou dos dois lados:

- **Direção A (YouTube → Spotify)**: A taxa de Call2Go de um artista no YouTube prevê a popularidade/seguidores dele no Spotify? (Ou seja: usar Call2Go faz crescer no Spotify?)

- **Direção B (Spotify → YouTube)**: A popularidade/seguidores de um artista no Spotify prevê as visualizações dele no YouTube? (Ou seja: quem é grande no Spotify também é grande no YouTube?)

9.3 Resultados

Direção	O que foi correlacionado	ρ	p	Sig.
A: YT → SP	Taxa Call2Go ↔ Popularidade Spotify	0,008	0,947	n.s.
A: YT → SP	Taxa Call2Go ↔ Seguidores Spotify	0,019	0,877	n.s.
B: SP → YT	Popularidade Spotify ↔ Média views YT	0,505	$< 0{,}001$	***
B: SP → YT	Seguidores Spotify ↔ Média views YT	0,674	$< 0{,}001$	***

*n.s. = não significativo; *** = altamente significativo ($p < 0{,}001$); SP = Spotify; YT = YouTube*

Como ler cada linha:

- **Direção A, linha 1 ($\rho = 0{,}008$, $p = 0{,}947$)**: A taxa de Call2Go de um artista **praticamente não tem relação** com a popularidade dele no Spotify. Um ρ de 0,008 é indistinguível de zero. O $p = 0{,}947$ confirma: há 94,7% de chance de essa correlação mínima ser puro acaso.
- **Direção A, linha 2 ($\rho = 0{,}019$, $p = 0{,}877$)**: Mesma conclusão para seguidores. Usar Call2Go no YouTube não prevê quantos seguidores o artista tem no Spotify.
- **Direção B, linha 1 ($\rho = 0{,}505$, $p < 0{,}001$)**: Artistas com mais popularidade no Spotify tendem a ter mais visualizações no YouTube. Um $\rho = 0{,}505$ é uma correlação **moderada a forte**. O $p < 0{,}001$ significa que há menos de 0,1% de chance de ser acaso — é uma relação real e confiável.
- **Direção B, linha 2 ($\rho = 0{,}674$, $p < 0{,}001$)**: Artistas com mais **seguidores** no Spotify têm muito mais visualizações no YouTube. Um $\rho = 0{,}674$ é uma correlação **forte**. A relação é mais clara ainda com seguidores do que com popularidade.

Conclusão principal da análise bidirecional: A influência vai de **Spotify para YouTube**, e não o contrário. Quem é grande no Spotify também é grande no YouTube. Mas usar Call2Go no YouTube **não garante** crescimento no Spotify. A "causalidade percebida" é invertida: a estratégia pode até ajudar individualmente, mas no conjunto dos 67 artistas não aparece como fator determinante.

O que o heatmap mostra (Figura 2): É uma grade colorida onde cada célula representa a correlação entre duas variáveis. A **parte de cima** da figura (Direção A) está em tons frios (azul): correlações baixas, quase zero. A **parte de baixo** (Direção B) está em tons quentes (laranja/vermelho): correlações altas. A assimetria visual entre as duas metades é a conclusão principal do estudo bidirecional.

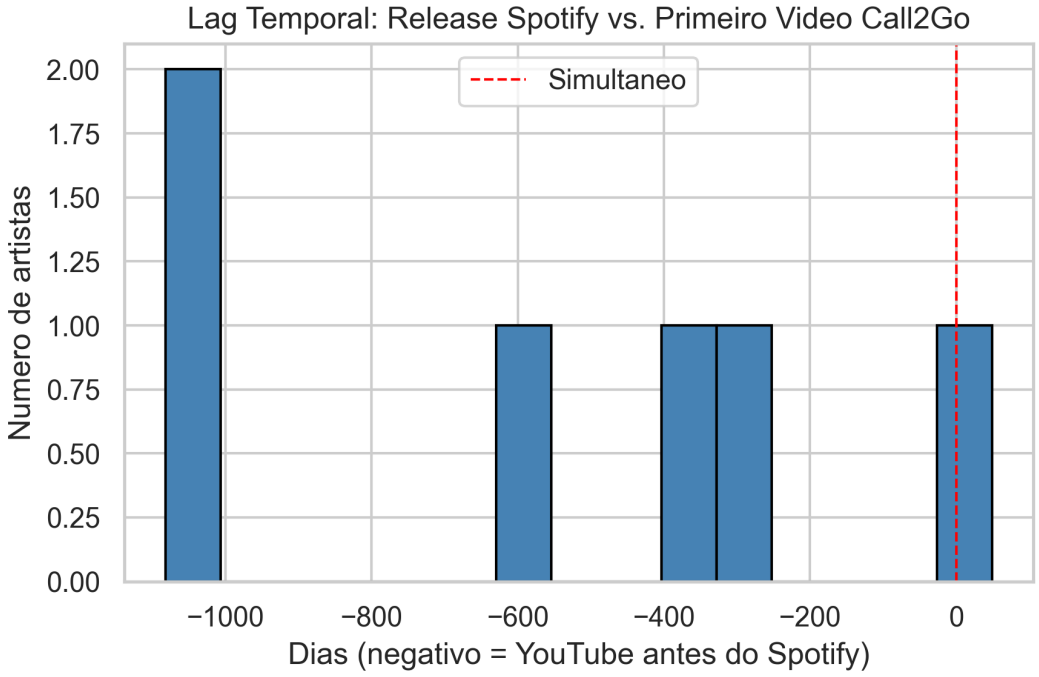

Figura 3: Defasagem temporal (dias) entre atividade no YouTube e entrada nos charts Spotify BR ($n = 39$ artistas). Valores negativos = YouTube veio antes dos charts.

10 Análise temporal: o YouTube precede os charts

10.1 O que é o "lag" (defasagem)?

Lag é a **diferença em dias** entre dois eventos:

- **Evento 1**: Data do primeiro vídeo publicado pelo artista no YouTube.
- **Evento 2**: Data em que o artista apareceu pela primeira vez no Top 200 Brasil do Spotify.

Se o lag é **negativo** (ex.: −882 dias), significa que o YouTube veio **antes** dos charts — o artista já publicava no YouTube quase 882 dias antes de entrar nos charts do Spotify.

10.2 Por que só 39 artistas?

Dos 67 artistas, só foi possível calcular o lag para **39** porque:

- Era preciso saber a data exata do primeiro vídeo no YouTube E a data de estreia nos charts do Spotify.
- Nem todos os artistas tinham dados históricos suficientes disponíveis nas APIs no momento da coleta.

10.3 Resultados principais

- **Mediana de −882 dias**: Em metade dos 39 artistas, o YouTube veio pelo menos **882 dias** (cerca de **2,5 anos!**) antes de entrarem nos charts do Spotify. O YouTube é literalmente o palco onde a reputação é construída antes do sucesso nos charts.
- **IQR:** [−1.814; −360] **dias**: O intervalo onde ficam os 50% do meio dos artistas. Mesmo o extremo menor é −360 dias — quase um ano de antecedência. E o extremo maior é −1.814 dias — quase 5 anos!
- **95% dos artistas** tinham o YouTube precedendo os charts: apenas 2 artistas (5%) tinham entrado nos charts antes de começar a publicar no YouTube.
- **18 artistas com Call2Go pré-chart**: dos 39, 18 usaram Call2Go **antes** de entrar nos charts. A mediana do lag de Call2Go desses 18 foi de −824 dias. E **89% (16 de 18)** deles adotaram a estratégia antes da estreia nos charts.

10.4 Os preditores temporais (Tabela de correlações)

Foram testadas 3 correlações para entender o que, na atividade do YouTube, está relacionado com o desempenho posterior nos charts:

O que foi testado	ρ	p	**Sig.**
Vídeos publicados nos 30 dias antes dos charts ↔ Score combinado	0,364	0,022	*
Lag Call2Go (dias) ↔ Score Spotify	0,028	0,913	n.s.
Call2Go presente pré-chart (sim/não) ↔ Score Spotify	−0,093	0,575	n.s.

* $p < 0{,}05$; *n.s. = não significativo*

Como interpretar:

- **Linha 1** ($\rho = 0{,}364$, $p = 0{,}022$) — **o único preditor significativo**: Artistas que publicaram mais vídeos no YouTube nos **30 dias imediatamente antes** de entrar nos charts tendem a ter um score combinado melhor. $\rho = 0{,}364$ é uma correlação fraca a moderada, mas o $p = 0{,}022$ confirma que não é acaso. Faz sentido intuitivamente: mais conteúdo recente = mais visibilidade = mais momentum = melhor posicionamento inicial nos charts.
- **Linha 2** ($\rho = 0{,}028$, $p = 0{,}913$): O tempo de antecedência do Call2Go (quantos dias antes dos charts o artista começou a usar Call2Go) **não prevê** o score no Spotify. Adotar Call2Go mais cedo não garante mais popularidade.
- **Linha 3** ($\rho = -0{,}093$, $p = 0{,}575$): Ter ou não ter usado Call2Go antes de entrar nos charts não tem relação com a popularidade posterior no Spotify.

O que o gráfico temporal mostra (Figura 3): Cada ponto é um artista. O eixo X é a defasagem em dias. A grande maioria dos pontos está à esquerda de zero (YouTube veio antes dos charts). A linha central (mediana) está em −882 dias, dividindo os artistas ao meio.

11 Last.fm e auditoria de voltas

11.1 O que é o Last.fm nesse contexto?

Last.fm é uma rede social de música que registra automaticamente o que você ouve em qualquer player compatível. Cada reprodução registrada é chamada de *scrobble*. Ela serve como **terceira plataforma independente**: se um artista é realmente popular no Brasil, ele deveria aparecer no YouTube E no Spotify E no Last.fm.

Dos 67 artistas, **9 (13,4%)** estavam ao mesmo tempo no Top 200 Brasil do Last.fm. Isso é esperado: o Last.fm tem base de usuários menor e mais específica que Spotify e YouTube.

11.2 Correlação Last.fm × Spotify

- $\rho = 0{,}848$**,** $p < 0{,}001$: Artistas com mais seguidores no Spotify têm significativamente mais scrobbles no Last.fm. Um $\rho = 0{,}848$ é uma correlação **muito forte** — quase perfeita. Isso serve como **validação cruzada** dos dados: confirma que os dados do Spotify estão corretos e que os artistas analisados são de fato populares de forma consistente entre plataformas.

11.3 Call2Go afeta métricas no Last.fm?

- **Listeners Last.fm:** $p = 0{,}865$ **(n.s.)**: artistas com Call2Go não têm mais ouvintes mensais no Last.fm.
- **Scrobbles Last.fm:** $p = 0{,}960$ **(n.s.)**: artistas com Call2Go não têm mais scrobbles registrados.
- **Presença nos charts Last.fm:** $\chi^2 = 2{,}610$**,** $p = 0{,}106$ **(n.s.)**: usar Call2Go não prevê aparecer nos charts do Last.fm.
- **Gênero musical:** $\chi^2 = 2{,}293$**,** $p = 0{,}682$ **(n.s.)**: o gênero musical do artista (sertanejo, funk, pop etc.) não influencia no uso de Call2Go.

Resumo: o Call2Go não tem relação com popularidade no Last.fm também. A consistência de resultados nulos nas três plataformas fortalece a conclusão do estudo.

11.4 O que é a "auditoria de voltas"?

A auditoria verificou se algum artista criava um **ciclo bidirecional**: link do YouTube apontando para Spotify (Call2Go) E link do Spotify/Last.fm apontando de volta para o YouTube.

Resultado: **0 de 67 artistas** tinham links reversos em nenhuma das 4 direções verificadas. Ou seja, a estratégia é **estritamente unidirecional**: YouTube leva para Spotify, mas Spotify não leva de volta para YouTube.

12 A validação do detector

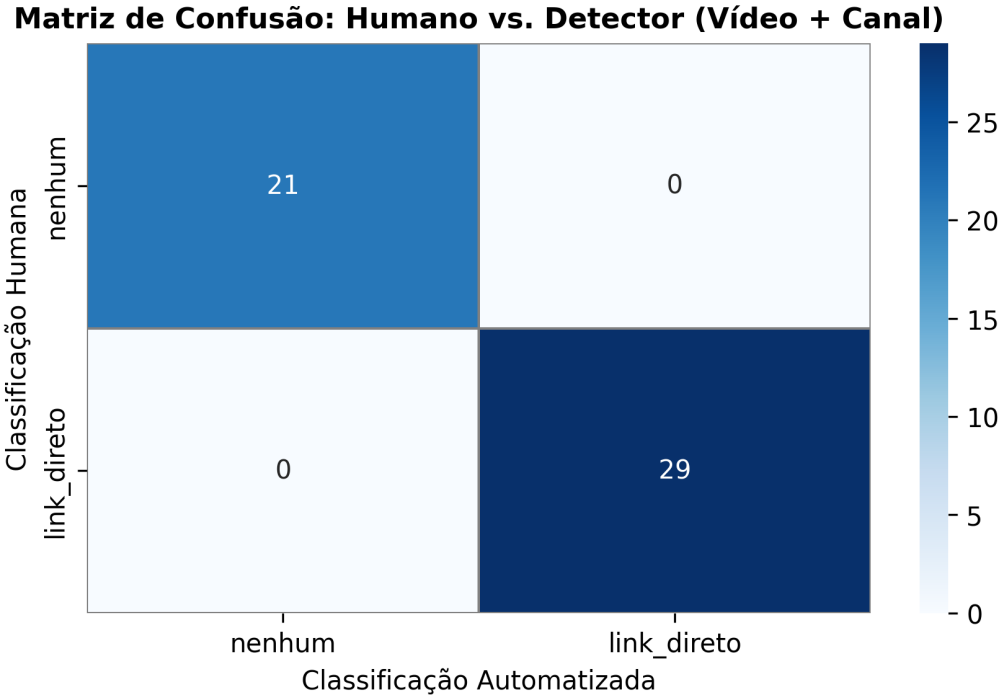

Figura 4: Matriz de confusão: comparação entre o detector automático e a classificação humana (91 vídeos adversariais, anotação às cegas). Esquerda: nível canal. Direita: nível vídeo.

12.1 O que é a validação cruzada do detector?

Para saber se o detector está **acertando**, ele foi testado contra a opinião de um humano. A metodologia foi:

1. Selecionou-se **91 vídeos adversariais**: casos propositalmente difíceis de classificar (os mais ambíguos do corpus).
2. Um anotador humano analisou cada vídeo **sem saber** o que o detector tinha classificado — isso é chamado de *anotação às cegas*, e serve para evitar que o humano seja influenciado pela resposta do detector.
3. As classificações do humano foram comparadas com as do detector.

12.2 O que é a Matriz de Confusão?

A matriz de confusão (Figura 4) divide os resultados em 4 categorias:

- **VP (Verdadeiro Positivo)**: detector disse "*tem Call2Go*" e humano concordou. **Acerto.**
- **VN (Verdadeiro Negativo)**: detector disse "*sem Call2Go*" e humano concordou. **Acerto.**

- **FP (Falso Positivo)**: detector disse "*tem Call2Go*" mas humano discordou. **Erro: detector marcou algo que não era Call2Go.**
- **FN (Falso Negativo)**: detector disse "*sem Call2Go*" mas humano disse que tinha. **Erro: detector perdeu um Call2Go real.**

A **acurácia** é simplesmente: (VP + VN) / total. Ou seja, a porcentagem de vezes que o detector acertou.

12.3 O que é o Kappa de Cohen (κ)?

A acurácia simples pode enganar. Se o detector dissesse "sem Call2Go" para **tudo**, acertaria 68,4% das vezes — porque 68,4% dos vídeos realmente não têm Call2Go! Seria uma acurácia alta, mas o detector seria inútil.

O *Kappa de Cohen (κ)* desconta esse acerto esperado por coincidência. Ele responde: *"Quanto **melhor que o acaso** o detector está acertando?"*

Escala de interpretação do κ (Landis & Koch, 1977):

κ	Interpretação
$< 0{,}20$	Péssimo
0,21–0,40	Fraco
0,41–0,60	Moderado
0,61–0,80	Substancial (bom)
$> 0{,}80$	Quase perfeito

12.4 Resultados da validação

Nível	**Acurácia**	κ	**Interpretação**	**Passou?**
Canal (bio/links)	90,1%	0,80	Substancial	**Sim ($\geq$ 85%)**
Vídeo (descrição)	82,4%	0,45	Moderado	**Não ($<$ 85%)**

Como interpretar:

- **Nível Canal (κ = 0,80, acurácia = 90,1%)**: O detector de canal **passou no teste**. O limiar definido era de **85%** de acurácia, e ele ficou em **90,1%**. Um κ de 0,80 está no topo da faixa "substancial", quase na categoria "quase perfeito". Isso significa que o detector de canal é **confiável para uso em pesquisa**.
- **Nível Vídeo (κ = 0,45, acurácia = 82,4%)**: O detector de vídeo **ficou 2,6 pontos percentuais abaixo do limiar** de 85%. O κ = 0,45 é "moderado" — funciona, mas com uma margem de erro maior. Casos onde só o vídeo (e não o canal) detectou Call2Go devem ser interpretados com mais cautela.

- **Por que a diferença entre os dois níveis?** A detecção no canal é mais fácil: os links na aba "Sobre" do YouTube são estruturados e bem formatados. A detecção no vídeo é mais difícil: a descrição é texto livre — cada artista escreve de um jeito diferente, com abreviações, emojis e variações imprevisíveis.

13 O que concluímos? (H0 a H4 em linguagem direta)

O TCC testou 5 hipóteses. Aqui está o resultado de cada uma em linguagem direta, sem fórmulas:

H0/H1 — O detector é confiável?

Parcialmente sim.

O detector de **canal** é confiável (90,1% de acurácia, $\kappa = 0{,}80$) e passou no limiar definido. O detector de **vídeo** é razoável mas não chegou ao limiar (82,4%, $\kappa = 0{,}45$). Para análises futuras, o nível canal é o mais recomendado. O detector combinado (OR/AND) pode ser usado com a ciência de que o componente de vídeo tem maior margem de erro.

H2 — Call2Go aumenta visualizações no YouTube?

Não encontramos evidência.

$p = 0{,}872$ (OR). Vídeos com e sem Call2Go têm praticamente as mesmas visualizações. Colocar o link do Spotify na descrição não está se traduzindo em mais views.

H3 — Call2Go aumenta popularidade no Spotify?

Não encontramos evidência.

$p = 1{,}000$ (OR). Artistas com mais Call2Go têm a mesma popularidade no Spotify que artistas sem Call2Go. O $p = 1{,}000$ é o valor mais extremo possível de "sem diferença alguma".

H4 — A atividade no YouTube precede a entrada nos charts Spotify?

Sim, e de forma muito expressiva.

Em 95% dos artistas, o YouTube veio antes dos charts. A mediana foi de 882 dias (mais de 2 anos) de antecedência. O único preditor estatisticamente significativo foi o volume de publicações nos 30 dias antes da estreia nos charts ($\rho = 0{,}364$, $p = 0{,}022$): quem publicou mais perto da estreia performou melhor nos charts.

Correlação bidirecional (adicional)

Spotify influencia YouTube, não o contrário.

A fama no Spotify prevê as visualizações no YouTube ($\rho = 0{,}674$), mas usar Call2Go no YouTube não prevê nada no Spotify ($\rho = 0{,}008$). O sentido da influência é Spotify $\rightarrow$ YouTube, não YouTube $\rightarrow$ Spotify.

Grande conclusão do TCC em uma frase: Encontramos que o YouTube é usado como palco de construção de audiência **muito antes** do sucesso no Spotify, mas a estratégia de Call2Go, apesar de amplamente adotada (31,6% dos vídeos), não mostra impacto estatístico mensurável nas métricas de engajamento.

14 Glossário rápido

API Interface que permite que um programa acesse dados de outro sistema de forma automática. Ex.: a API do Spotify permite consultar popularidade e seguidores de qualquer artista via código Python.

Bootstrap (IC 95%) Técnica estatística que repete a análise **10.000 vezes** com amostras ligeiramente diferentes para calcular intervalos de confiança sem precisar assumir que os dados têm distribuição normal.

Call2Go Chamada de ação num vídeo do YouTube que direciona o ouvinte para o Spotify.

Chart Ranking das músicas ou artistas mais ouvidos/vistos numa plataforma. Ex.: Spotify Top 200 Brasil, YouTube Top 100 Brasil.

Cross-platform Que envolve mais de uma plataforma digital ao mesmo tempo. Aqui: YouTube + Spotify + Last.fm.

EDA (Exploratory Data Analysis) Análise exploratória de dados: a etapa de "olhar os dados" antes de qualquer teste formal, usando gráficos e estatísticas descritivas.

Kappa de Cohen (κ) Medida de concordância entre dois classificadores que desconta a concordância esperada por acaso. Vai de 0 (puro acaso) a 1 (concordância perfeita).

Lag (defasagem) Diferença em dias entre dois eventos temporais. Aqui: dias entre o primeiro vídeo no YouTube e a estreia nos charts do Spotify.

Mann-Whitney U Teste estatístico para comparar dois grupos sem assumir que os dados seguem distribuição normal.

Pipeline ETL Sequência automatizada de passos: **E**xtração de dados, **T**ransformação e **L**arga (*Extract, Transform, Load*).

Regex (expressão regular) Sistema de busca de padrões em texto usando regras formais. É como um Ctrl+F avançado que entende variações, proximidade e contexto.

Scraping Técnica de coleta automática de dados de páginas web que não têm API disponível. O programa lê o HTML da página e extrai as informações de interesse.

Scrobble (Last.fm) Registro de uma música ouvida na plataforma Last.fm. Cada vez que você reproduz uma música, um "scrobble" é adicionado ao seu perfil.

Spearman (ρ) Coeficiente de correlação que usa posições (rankings) em vez de valores brutos. Vai de -1 a $+1$.

Star schema Modelo de banco de dados com uma tabela central de fatos (os dados principais) e tabelas de dimensão ao redor. É o modelo padrão para bancos de dados voltados a análises.

Valor-p (p-value) Probabilidade de observar o resultado obtido **por acaso**, assumindo que não existe efeito real. $p < 0{,}05$ = resultado significativo (difícil de ser acaso); $p \geq 0{,}05$ = sem evidência de efeito.

Colinha criada em 29/04/2026 para alinhamento com orientador.
Para uso exclusivo do autor.

Todos os dados são provenientes do pipeline TCC Call2Go (commit `0bdfcf7`).